COMP5423 自然语言处理小组项目要求

技能增强型搜索智能体

基本信息

主题：技能增强型搜索智能体（Skill-Augmented Search Agent）。

小组人数：每组 4 人；允许两个指定小组各有 3 人。

截止时间：2026 年 11 月 26 日 23:59（香港时间）。

助教：Runyang You（25093051r@connect.polyu.hk）；Hongru Cai（25145475r@connect.polyu.hk）；Zhenning Shi（26035798r@connect.polyu.hk）。

原文版本：2026 年 8 月 v1.0。

项目目标

开发一个技能增强型搜索智能体，利用固定文档集合回答具有挑战性的问题。系统应将检索、大语言模型（LLM）推理、工具使用和可复用技能整合为端到端工作流程。

与单轮检索增强生成（RAG）流程不同，智能体应能执行多步搜索，例如改写查询、调用搜索辅助工具、查看文档、收集证据、应用相关技能、核验答案，并决定何时停止。

所有小组必须通过 API 使用相同的指定 LLM 基座。本项目不要求训练或微调大语言模型。应通过检索设计、工具协调、智能体流程、上下文管理和技能设计改进系统。搜索智能体与智能体式深度研究的代表论文见参考文献 [12–14]。

项目资源

使用 BrowseComp-Plus [1]，该基准在包含 100,195 篇文档的固定集合上评估搜索智能体。Hugging Face 已提供从原数据集中抽取的 100 道验证题及答案。另有 100 道不公开答案的测试题，将于提交截止日期前两周发布，用于最终性能评估。验证集和测试集使用相同文档集合。

验证集：100 题，提供 ID、问题、答案。

测试集：100 题，提供 ID、问题。

文档集合：100,195 篇，提供文档 ID、正文、来源 URL。

验证集链接：https://huggingface.co/datasets/HongruCai/COMP5423-BrowseComp-Plus-Val

官方指定基座为 DeepSeek-V4-Flash [18]。可用 API 服务见 [27–31]；也可使用提供相同模型及功能的其他 API 服务。

评分构成

系统实现 40%；书面报告 20%；演示视频 20%；系统性能 20%。

1 系统实现 40%

系统应包含检索方法、多种搜索辅助工具、使用工具的搜索智能体、可复用技能和简单用户界面。同一实现必须能够直接运行已发布的验证集和测试集文件，不能逐题手动修改问题或答案。

1.1 检索方法与工具设计 12%

检索方法（8%）

至少实现以下一类检索方法：

• 稀疏检索，例如 TF-IDF、BM25 [2]，或使用神经模型预测词项权重。

• 基于编码器模型的稠密检索，例如 E5 [4]、BGE [5]、GTE [6]。

• 使用 LLM 嵌入模型、能够感知指令的稠密检索，例如 Qwen3-Embedding [7]、E5-Mistral [8]。

实现资源示例包括 BM25S [3]、FAISS [9] 和 FlagEmbedding [17]。所有检索方法必须通过一个统一检索工具提供给智能体。该工具应接收搜索查询，返回排序后的文档标识符、得分和文本片段。

可以通过融合、内部路由或方法选择参数结合多种检索方法。无论内部如何设计，提供给智能体的检索工具必须恰好只有一个，不能为不同检索器分别提供独立工具。

评分规则：实现一类检索得 4 分，两类得 6 分，三类全部实现得 8 分。同一类别中实现多个方法，仍只计为一类。

工具设计（4%）

除统一检索工具外，智能体应至少拥有另一类辅助工具，例如打开文档、在文档内查找文本、查看元数据或筛选搜索结果。示例见 [19,20]。

每个工具应具有清晰的名称、功能、输入和输出，且可由智能体调用。报告应列出工具类型总数并逐一说明。

评分规则：只有统一检索工具得 2 分；统一检索工具加至少一类辅助工具得 4 分。只有实际实现且可由智能体调用的工具才计入。

1.2 搜索智能体设计 14%

必须通过 API 使用指定 LLM 基座。基础工具使用智能体为必做项；功能 A、B 为可选扩展，只有实际实现后才能获得对应分数。基础组件与两项扩展全部完成，才能获得本部分满分。是否实现将根据报告、演示视频和提交代码判断。

基础工具使用智能体（4%）：接收问题，从可用工具中选择适当工具，生成工具输入，执行工具，并利用返回信息作答。

功能 A 迭代式智能体循环（5%）：超越固定的单次处理流程，支持后续行动依赖此前搜索结果的迭代循环。例如改写或分解查询、再次检索、检查更多文档、核验候选答案，或判断证据是否充分。也可自行设计其他迭代流程。没有基于结果进行迭代的固定“检索后生成”流程，不算完整的迭代式智能体循环。示例见 ReAct 和智能体循环教程 [10,21,22]。

1.2 搜索智能体设计 续

功能 B 上下文管理（5%）：智能体应维护独立于原始对话历史的结构化内部状态，记录已访问文档、选中证据和当前搜索进度，例如正在处理的子查询或候选答案。

至少实现一种控制传入 LLM 上下文的方法，例如去重、选择、裁剪、压缩或摘要。仅将全部历史消息和工具输出不断追加到提示词中，不算完整的上下文管理。状态、裁剪、摘要和记忆示例见 [11,23,24]。

1.3 可复用技能 10%

技能是一种在特定情境下指导智能体行动的可复用流程，例如分解多线索问题、消除实体歧义，或从失败搜索中恢复。

基础技能结构（6%）：每组至少实现一个符合 Agent Skills 规范 [15] 的技能。可以学习现有技能作为参考，但不得复制、直接复用或提交他人创建的技能。每个技能必须存放在目录中，采用以下标准结构：

```
skill-name/
|-- SKILL.md      必需
|-- scripts/      可选
|-- references/   可选
`-- assets/       可选
```

必需文件 SKILL.md 须包含 YAML frontmatter（文件开头的元数据），至少具有 name 和 description 字段，其后为 Markdown 格式的指令。按需可附带脚本、参考资料、素材或其他支持文件。

不得将技能完整指令永久放入基础提示词。智能体应在运行时加载技能目录，并遵循其指令。

加分项 自动选择技能（4%）：要取得这部分分数，至少提供两个功能不同的技能。智能体应根据当前问题或搜索状态自动决定加载哪个技能，而非要求用户指定；也可以决定不使用技能。报告和演示应展示不同问题如何触发不同的技能选择决策。

1.4 用户界面 4%

可以使用终端界面或网页界面。用户应能输入问题，并查看最终答案、支持证据、所选技能及工具使用过程。界面清晰易读即可，不要求复杂视觉设计。

2 书面报告 20%

所有小组必须使用指定 Overleaf 模板：https://www.overleaf.com/read/wdbsnbtqwcrv#5382c5

报告正文至少 4 页，不包括参考文献及 Contribution and Declaration（贡献与声明）部分；以 PDF 格式提交。

最终报告必须保留并填写模板末尾的贡献与声明部分。成员贡献比例之和必须为 100%，每名成员都必须签名。该部分不完整的报告将不被接受。

报告应包含：

- 系统设计方法：说明整体设计及关键组件。
- 系统流程图：提供有标注的图示，展示从问题输入到最终答案的流程。
- 结果分析：分析不同系统配置下的实验结果，并附相关表格或图形。
- 用户界面设计：提供截图，说明用户如何与系统交互。
- 额外探索（可选）：说明其他实验、功能或优化尝试。

3 演示视频 20%

视频不得超过 5 分钟，提交格式为 MP4。视频应：

• 演示系统实际运行，并突出解决的主要挑战。

• 展示小组申请计分的功能或加分项。

• 简要介绍代码结构，解释主要组件的作用。

视频旨在证明小组理解所提交系统，且报告描述的行为确实由该实现产生。

4 系统性能 20%

本部分有效提交可得 10 分，相对性能最多另得 10 分。提交 test_prediction.jsonl，每道测试题对应一个 JSON 对象，字段如下。请参考原文提供的示例文件。

```
{
  "id": <字符串>,
  "question": <字符串>,
  "answer": <字符串>,
  "trajectory": [<智能体步骤>, ...],
  "tool_calls": <整数>,
  "total_tokens": <整数>
}
```

每道题的 trajectory 必须按时间顺序、以机器可读形式记录完整智能体过程。tool_calls 统计智能体发起的所有工具调用，不包括工具内部操作。total_tokens 为该题所有 LLM 调用中，API 返回的 usage.total_tokens 的总和。

示例：https://huggingface.co/datasets/HongruCai/COMP5423-BrowseComp-Plus-Val/blob/main/examples/test_prediction.jsonl

有效系统提交（10%）

系统满足基础工具使用智能体要求，能端到端运行，并为 100 道测试题中的每一题生成恰好一条包含全部必需字段的有效记录，即可获得 10 分。答案错误不扣这 10 分。不满足上述要求，或包含人工构造预测或轨迹的提交，整个系统性能部分得 0 分，并取消相对性能排名资格。

相对性能（10%）

答案准确率最多 6 分，工具调用效率最多 2 分，token 效率最多 2 分。准确率采用归一化精确匹配（normalized EM）：将答案转为小写、移除标点和英文冠词 a、an、the，并规范化空白后，与参考答案比较，计算匹配比例。

效率以全部 100 道测试题的工具调用总数和 API token 总数衡量。EM 越高越好，调用数或 token 数越少越好。

每项指标将合资格小组从优到劣排名，分配从 100 到 0 等距排列的百分位分数；并列小组取对应并列名次分数的平均值。三项百分位分数分别记为 P_EM、P_calls、P_tokens。

系统性能得分 = 10 + 6 × P_EM / 100 + 2 × P_calls / 100 + 2 × P_tokens / 100，结果四舍五入至小数点后两位。

示例：有效提交，EM 百分位 80、工具调用百分位 60、token 百分位 40，则得分为 10 + 4.8 + 1.2 + 0.8 = 16.8 分（满分 20）。

5 提交要求

整个小组通过 Canvas 提交一个压缩包。推荐目录结构如下：

```
Group-X.zip
|-- test_prediction.jsonl
|-- code/
|   |-- README.md
|   |-- requirements.txt 或 environment.yml
|   |-- skills/
|   |   `-- skill-name/
|   |       |-- SKILL.md
|   |       |-- scripts/       可选
|   |       |-- references/    可选
|   |       `-- assets/        可选
|   `-- 主程序及配套源文件
|-- Group-X-Report.pdf
`-- Group-X-Video.mp4
```

1 预测文件及内嵌轨迹

test_prediction.jsonl 必须严格符合规定格式。每个 JSON 对象必须包含对应测试问题的完整轨迹，不需要单独的轨迹文件或目录。

2 代码目录

code/ 应包含运行系统所需的全部源文件。README 应说明代码结构、环境配置及依赖版本、如何根据测试题重新生成 test_prediction.jsonl，以及如何提供 LLM API 密钥。

提交内容中不得包含 API 密钥、密码、模型权重或其他凭据。必要时，可通过公开且只读的云端链接分享大型索引或模型文件。

3 报告和视频

最终报告命名为 Group-X-Report.pdf，演示视频命名为 Group-X-Video.mp4。

4 小组提交

每名学生都必须在 Canvas 加入对应小组。除两个指定的三人组外，每组 4 人。每组只需一名成员提交最终压缩包。

注意：未遵循规定目录结构或文件格式的提交，可能无法被正确评估。上传前请在本地测试打包后的提交内容，确保系统能够端到端执行。

迟交政策

每迟交一天，扣除总分的 10%。迟交超过 3 天将不被接受，成绩为 0 分。

学术诚信与核验

所有提交答案及内嵌轨迹都必须由所提交系统生成。不得硬编码测试答案、使用问题到答案的查找表、人工修改单条预测，或直接使用隐藏标签。

教学团队可能检查源代码、比较预测与内嵌轨迹、询问具体实现选择，或按需重新运行部分案例。各组必须保留可用的系统环境及相关 API 配置，直至评分结束。

参考文献与资源

以下编号与原文一致；论文名称译为中文，模型与资源名称保留原名。链接沿用原文。

论文

[1] Zijian Chen、Xueguang Ma、Shengyao Zhuang 等，2026。BrowseComp-Plus 深度搜索智能体的公平且解耦的评估基准。ACL 2026。

[2] Stephen Robertson、Hugo Zaragoza，2009。概率相关性框架 BM25 及其扩展。Foundations and Trends in Information Retrieval。

[3] Xing Han Lù，2024。BM25S 通过预先稀疏评分实现数量级更快的词汇搜索。

[4] Liang Wang、Nan Yang、Xiaolong Huang 等，2022。通过弱监督对比预训练学习文本嵌入。

[5] Shitao Xiao、Zheng Liu、Peitian Zhang 等，2024。C-Pack 通用中文嵌入资源包。SIGIR 2024。

[6] Zehan Li、Xin Zhang、Yanzhao Zhang 等，2023。通过多阶段对比学习构建通用文本嵌入。

[7] Yanzhao Zhang、Mingxin Li、Dingkun Long 等，2025。Qwen3 Embedding 通过基础模型推进文本嵌入与重排序。

[8] Liang Wang、Nan Yang、Xiaolong Huang 等，2024。利用大语言模型改进文本嵌入。ACL 2024。

[9] Jeff Johnson、Matthijs Douze、Hervé Jégou，2021。利用 GPU 进行十亿规模相似度搜索。IEEE Transactions on Big Data。

[10] Shunyu Yao、Jeffrey Zhao、Dian Yu 等，2023。ReAct 在语言模型中协同推理与行动。ICLR 2023。

[11] Charles Packer、Vivian Fang、Shishir G. Patil 等，2023。MemGPT 迈向作为操作系统的 LLM。

[12] Weizhi Zhang、Yangning Li、Yuanchen Bei 等，2025。从网络搜索迈向智能体式深度研究 通过推理智能体激励搜索。

[13] Xiaoxi Li、Guanting Dong、Jiajie Jin 等，2025。Search-o1 智能体搜索增强的大型推理模型。EMNLP 2025。

[14] Yuxuan Huang、Yihang Chen、Haozheng Zhang 等，2025。深度研究智能体 系统性审视与路线图。

资源

[15] Agent Skills。Agent Skills 规范。

[16] Texttron。BrowseComp-Plus 代码与数据。

[17] FlagOpen。FlagEmbedding 检索与重排序工具包。

[18] DeepSeek-AI，2026。DeepSeek-V4-Flash 模型卡。

[19] LangChain。工具。

[20] LangChain。Deep Agents 文件系统工具。

[21] LangChain。智能体与工具调用循环。

[22] LangChain。LangGraph Graph API 状态、分支与循环。

[23] LangChain。短期记忆。

[24] Anthropic，2025。面向 AI 智能体的有效上下文工程。

[25] Weizhi Zhang 等。Awesome Deep Research。

[26] RUC-NLPIR。Search-o1。

API

[27] DeepSeek。Chat Completions API。

[28] OpenRouter。DeepSeek-V4-Flash API。

[29] 阿里云百炼。DeepSeek API。

[30] SiliconFlow。Chat Completions API。

[31] 火山引擎。Ark API 文档。